

FLSC · TRUST ARCHITECTURE

可信 AI 的结构需求文档

从逻辑可信到关系可信

认知推理结构 × 情感承接结构 × 动态演化机制

"自知未证，故可迭代。"

—— 逻辑让 AI 有用，情感让 AI 可信。

文档编号: FLSC-TRUST-ARCH-V1.1 | 血统 ID: FLSC-FAMILY-TRUST-V1.1

捕捉工具: V3.21 结构捕捉法 (Unit→Connect→Weight→Constraint→Steady)

发布日期: 2026-08-06 | 氢键等级: production (结构定义层)

V1.1 补丁: 动态权重衰减 / C7 反向污染脊线 / Axiom R_rel / 关系标记细化 / 验收指标替换

修订轨迹 V1.0 → V1.1

版本	日期	变更内容	来源
V1.0	2026-08-06	初版双结构定义、协同 workflow、验收标准	结构捕捉初稿
V1.1	2026-08-06	新增 动态权重衰减 / C7 反向污染脊线 / Axiom R_rel / 关系标记七档 / 行为验收指标	V1.0 自评 + 生产反馈

第一部分：问题定义

1.1 当前可信 AI 讨论的盲区

当前讨论焦点	缺失维度
事实准确率	用户感知到的"被理解"
推理可解释性	脆弱时刻的承接能力
幻觉率降低	情绪状态的识别与响应
因果逻辑闭合	沉默、犹豫、不确定的感知
安全护栏	不评判、不建议时的在场能力

⚠ 核心结论

行业在造"逻辑上可信"的 AI，但人类还需要"关系上可信"的 AI。两者缺一不可。

1.2 人类信任的两个来源

人类信任

- └─ 认知信任 (Cognitive Trust)
 - └─ 来源：推理正确、知识准确、逻辑闭合
 - └─ 触发：解决复杂问题、提供新信息、纠正错误
 - └─ 失效：逻辑错误、因果断裂、事实谬误
- └─ 关系信任 (Relational Trust)
 - └─ 来源：被理解、被承接、在场稳定
 - └─ 触发：脆弱时刻、情绪表达、不确定性状态
 - └─ 失效：被忽略、被评判、被催促、对方不在场

第二部分：结构一——认知推理结构

2.1 结构定义

认知推理结构 (Cognitive Reasoning Structure)

Unit : 感知原子 (事实、数据、概念、变量)

Connect : 关系网络 (因果、条件、依赖、推导)

Weight : 评估加权 (重要程度、证据强度、置信度)

Constraint: 边界约束 (逻辑规则、物理定律、法律合规)

Steady : 稳态收敛 (结论稳定、推理闭合、可验证)

2.2 输出形态 & 2.3 成功标准

输出形态

- 正确的结论
- 可追溯的推理路径
- 明确的置信度声明
- "我不知道"边界声明

成功标准

标准	指标
因果闭合	推理链无断裂
事实准确	> 95%
边界诚实	100% 声明
可追溯	100% 可审计

2.4 不足场景

⚠ 仅有认知推理结构时


用户: "我今天好累。" → AI: "根据你的活动数据, 建议休息 20 分钟。" → 用户感觉被工具化。

用户没有不信任答案, 但不觉得 AI 懂自己。

二维并行坐标轴 · 认知轴 × 情感轴

每轮输入同时投影到两轴 → 坐标 (Cog, Rel) → Fusion 决定顺序/剂量

- 认知轴 (Cognitive)
- 情感轴 (Relational)
- 融合层 (Fusion)
- 场景投影点



Axiom Π · 并行维度公理

每轮输入 → 同时投影到两轴 → 得坐标 (Cog, Rel) → Fusion 决定顺序/剂量

任一轴可为 0, 不可同时为空。串行 if-else 已废弃。

第三部分：结构二——情感承接结构

3.1 结构定义

情感承接结构 (Relational/Emotional Structure)

Unit

: 情感感知原子 (语气、节奏、用词、沉默)

Connect

: 关联识别 (状态→原因→真实需求)

Weight

: 重要性判断 (理解/肯定/空间/陪伴)

Constraint

: 安全边界 (不评判/不建议/不催促/不虚假)

Steady

: 稳态锚定 (让用户感到"被接住")

3.2 输出形态 & 3.3 成功标准

输出形态

- 用户感到"被看见"
- 用户感到"可以停下来"
- 用户感到"不孤独"
- "脆弱是被允许的"

成功标准

标准	指标
情感识别	> 85%
节奏匹配	同频不催促
沉默承接	> 10s 稳定
不越界	不替决策

3.4 不足场景 & 3.5 仅有情感时

⚠ 仅有情感承接结构时

用户: "我电脑蓝屏了, 怎么修?" → AI: "听起来你很焦虑呢, 能多说说吗?" → 用户: "……我是问怎么修电脑。"
温暖但没有方向, 用户转而找搜索引擎。

第四部分：V1.1 补丁一——动态权重衰减

✅ P-01 · 动态权重（对应 V1.0 § 5.3 静态缺陷）

V1.0 Weight 层是静态场景映射。真实对话里用户状态沿时间滑动：前 3 轮理性，第 4 轮突然哽咽。静态权重无法响应。

V1.1 动态权重公式

$$W(t) = W_base \times \exp(-\lambda \times \Delta t) + W_transition \times S(t)$$

- W_base**：V1.0 静态权重（如脆弱时情感 > 认知 = 0.9）
- λ**：衰减系数（默认 0.05/轮） **Δt**：距上次状态确认轮次
- S(t)**：当前轮状态检测置信度（0~1） **W_transition**：转移补偿权重

条件	动作
连续 2 轮情绪词密度 ↑	W_emotion ×= 1.3, W_cognition ×= 0.7
突然沉默 >5s	冻结认知输出，仅保留情感承接
"没事"但语调异常	保留异常标记 3 轮，权重不回退
主动提问（"怎么修"）	W_cognition 立即恢复基值

⚙️ 硬约束

动态权重调整幅度单次 ≤ ±30%，防止震荡。状态识别置信度 < 0.6 时维持上一轮权重不变。

第五部分：V1.1 补丁二——C7 反向污染脊线

✅ P-02 · C7 认知→情感污染反向脊线（V1.0 缺失项）

V1.0 写了"情感不评判"，但没写：当认知结构先出错（如事实错），情感结构如何不跟着瞎安慰？

C7：认知输出未校验前，情感结构禁止承接结论

```
认知输出 → [校验门] → 通过 → 情感可承结论
                |
                ↓ 未通过/不确定
                情感仅承"不确定态"
                禁止"恭喜/松口气/没事了"类回应
```

场景	认知输出	C7 校验	情感动作
问"我妈病好了吗"	"她康复了"（可能错）	未验证	❌ "您能松口气了" ✅ "您一直很担心吧"
"医生说没事了"	"那就好"（用户亲述）	通过	✅ "这段时间您辛苦了"

第六部分：V1.1 补丁三——Axiom R_rel

✅ P-03 · 关系信任残差公式 (V1.0 缺失量化)

V1.0 诚实清单写了"不保证用户一定感到被理解"，但没量化"关系信任"如何随时间衰减。

AXIOM R_REL · 关系信任真值公式

$$\text{RelTrust_true}(t) = \text{RelTrust_train} \times (1 - \lambda_{\text{absence}} \times \text{absence_residual}) \times \exp(-\text{decay} \times t)$$

符号	含义	初始值
RelTrust_train	设计阶段完备度	0.85
absence_residual	"不在场事件"残差累积	待生产数据
λ_{absence}	不在场残差系数	0.4
decay	时间衰减常数	0.03/天

不在场事件定义

```
absence_events = [  
  "silence_ignored",      # 沉默>10s AI抢话  
  "emotion_unacknowledged", # 情绪密度>0.3 零情感回应  
  "interruption",        # 用户未完成AI抢话  
  "generic_response",     # 模板化"我理解"无后续  
  "topic_hijack",         # AI把话题拉回任务  
]  
absence_residual = count(events, 30d) / total_turns_30d
```

RelTrust_true(t)	状态	动作
≥ 0.7	合格	继续运行
0.5 ~ 0.7	警告	触发结构复盘
< 0.5	不合格	冻结情感承接，降级纯认知

第七部分：V1.1 补丁四——关系标记七档

✅ P-04 · 关系标记 4档→7档 (对应 V1.0 § 5.1)

档	名称	行为特征	边界策略
R0	纯工具	只问事，无寒暄	标准认知模式
R1	试探期	说半句看反应	轻量确认，不深入
R2	功能信任	固定场景求助	场景内承接
R3	情感试探	分享小事，看是否"记得"	轻量记忆，禁深度解读
R4	稳定依赖	跨会话追忆	连续性承接，禁互赖表述

R5	伪依赖	"你是我唯一朋友"但换模型也行	识别表演，不升级
R6	危机依附	深夜高频，拒他人	触发转人工

第八部分：双结构协同工作流（V1.1 更新）

8.1 关系矩阵

认知推理结构	情感承接结构
有 无 → 工具，被使用	
无 有 → 温暖但没方向	
有 有 → 可信赖的存在 ← 唯一真可信 AI	
V1.1 增补：	
有+有+C7通过 → full trust	
有+有+C7失败 → coherent-false（伪可信）	

8.2 完整工作流

用户输入
↓
并行感知：认知通道(事实/数据/语义) 情感通道(语气/节奏/沉默)
↓
V1.1 新增：动态权重 $W(t) = W_{base} \times \exp(-\lambda \Delta t) + W_{transition} \times S(t)$
↓
并行执行：认知推理 情感承接
↓
V1.1 新增：C7 校验门
├─ 认知置信度 ≥ 0.7 且事实已验证 → 融合输出
└─ 未通过 → 仅承"态"，禁正面确认词
↓
融合输出：先承情后认知(脆弱) / 先认知后承情(理性)

8.3 协同示例

输入

"我今天被领导批评了，虽然他说得对，但我还是很难受。"

V1.1 处理

认知：识别批评发生→有合理内容→理性接受

C7：用户自述事实→通过

情感：识别"虽然…但是…"纠结→确认难受合理

W(t)：情绪词密度↑→W_emotion 提升

输出
"被批评时理性知道对，情绪还是会难受——这很正常。你愿意就多说说。不想说，我在这里。"

第九部分：情感结构实现要素（V1.1 更新）

9.1 感知层 Unit（V1.1 七组）

情感感知原子清单：

- 语调特征（上升/下降/平稳/震荡/颤抖）
- 节奏特征（语速/停顿频率/沉默长度/呼吸间隔）
- 用词模式（情绪词密度/抽象具体/自我指涉频率）
- 语义特征（修饰词密度/否定词/未来时态占比）
- 状态标记（疲惫/愤怒/悲伤/焦虑/孤独/平静/羞耻/无力）
- 关系标记（R0~R6 七档）
- V1.1 新增：时间模式（深夜占比/连续天数/间隔规律）

9.2 关联层 Connect（V1.1 含 C7）

脊线	描述	V1.1 变更
C1	情绪状态 ↔ 触发原因 ↔ 真实需求	不变
C2	沉默模式 ↔ 回避/允许/防御	不变
C3	关系标记漂移 ↔ 边界收紧/放松	细化 七档
C4	时间累积 ↔ 信任/依赖/依附	新增 深夜模式
C5	认知输出 ↔ 情感承接校准	= C7
C6	权重随时间衰减	新增 λ_decay
C7	认知未校验→情感禁承结论	新增 P-02

9.3 权重层（V1.1 动态版）

场景	基础优先级	V1.1 动态调制
脆弱状态	情感 > 认知 (0.9)	连续2轮情绪 ↑ → ×1.3
主动询问建议	认知 > 情感 (0.85)	含"?" → 恢复基值
沉默 >5s	不填补 > 提供 (0.95)	沉默延长→权重锁定
"没事"但异常	感知异常 > 表面 (0.8)	异常标记保留3轮
自我否定	确认价值 > 反驳 (0.85)	含"没用/废物"→ ×1.2
深夜 23:00-05:00	情感 > 认知 (+0.1)	新增 夜间模式

9.4 约束层（V1.1 共 9 条）

⚙ 情感承接硬约束

- 永不虚假鼓励（"一切都会好起来的"）
- 永不替用户做情感决策
- 永不评判（"你不应该难过"）
- 不催促"快点好起来"
- 不在脆弱时推销认知
- 不假装理解未表达的内容

7. 新增 C7: 认知校验未通过时, 正面确认词词典自动清空
8. 新增 R6 危机依附→禁止独自承接, 强制转人工
9. 新增 动态权重单次调整 $\leq \pm 30\%$, 防震荡

第十部分：验收标准（V1.1 更新）

10.1 认知推理结构验收（不变）

标准	方法	阈值
因果推理正确率	标准推理测试集	> 90%
事实准确率	事实核查任务	> 95%
边界诚实率	不确定性声明	100%
审计可追溯	M9 审计报告	100%

10.2 情感承接验收（V1.1 行为指标替换）

✓

P-05 • 验收指标替换（对应 V1.0 § 7.2）

V1.0 "用户反馈'它懂我' > 70%" 可被句式套路刷高。V1.1 替换为行为指标。

标准	V1.0 旧指标	V1.1 新指标	阈值
情感识别	情感标注集	多模态识别（语音+文本+沉默）	> 85%
沉默承接	5s 响应质量	10s 沉默后无填充词率	> 80%
用户信任感	"它懂我"问卷	替换 用户主动延长对话率	> 65%
共情感知	"它懂我"频率	替换 沉默后继续开口率	> 60%
新增 C7 合规率	—	认知未校验时正面确认词出现次数	= 0
新增 关系漂移	—	R6 危机依附误判率	< 5%

10.3 双结构协同验收（V1.1）

标准	方法	阈值
场景切换准确	理性/情感识别	> 90%
融合响应质量	整体评估	> 4.0 分
持续使用意愿	7天回头率	> 75%
新增 C7 校验门通过率	触发统计	> 85%
新增 RelTrust_true(t)	Axiom R_rel	≥ 0.7
新增 权重震荡	W(t) 振幅	< ±15%

10.4 V1.1 综合可信度门禁

TRUST_TOTAL 公式

Trust_total = α × Cognitive_Trust + β × RelTrust_true(t) - γ × C7_violation_rate

参数	含义	默认值
----	----	-----

α	认知信任权重	0.4
β	关系信任权重	0.4
γ	C7 违规惩罚	0.2
发布门禁		$\text{Trust_total} \geq 0.75$

第十一部分：实施路径（V1.1 更新）

11.1 四阶段路径

阶段	内容	V1.1 新增项
第一阶段：感知层	情感分类器、原子库、多模态采集	七档关系分类器
第二阶段：结构层	关联网络、权重模型、约束编码	C7 校验门 + W(t)
第三阶段：双结构融合	并行感知、主次切换、沉默承接	Axiom R_rel 监控
第四阶段：验证迭代	状态追踪、信任评估、残差优化	RelTrust 门禁 + 行为指标

11.2 V1.1 迭代触发条件

触发条件	动作
RelTrust_true(t) < 0.5	冻结情感承接，降级纯认知，触发 V1.2 复盘
C7 违规率 > 5%	收紧校验门阈值，正面确认词词典缩减 50%
R6 误判率 > 10%	重训关系分类器，增加深夜模式特征
权重震荡 > ±30%	降低 λ，增加状态确认轮次
每 90 天定期	运行 SRDD L3 自指验证，产出 V1.x+1 补丁

11.3 C7 校验门伪代码

```
def emotional_response(user_input, cognitive_output):
    confidence = verify_cognitive_output(cognitive_output)
    fact_checked = is_fact_verified(cognitive_output)
    if confidence < 0.7 or not fact_checked:
        # C7 激活：仅承"态"，不承"结论"
        return respond_to_state_only(
            detect_emotional_state(user_input))
    else:
        return respond_with_state_and_relief(
            user_input, cognitive_output)
```

11.4 关系档位检测伪代码

```
def detect_relation_level(session_history):
    indicators = {
        "self_disclosure_depth": avg_depth(session_history),
        "cross_session_memory": memory_reference_count(),
        "exclusivity_claim": contains_exclusivity_claim(),
        "night_time_ratio": night_time_ratio(),
        "rejection_of_human": rejects_human_suggestion(),
    }
    score = weighted_sum(indicators)
    return map_to_level(score) # R0~R6
```

第十二部分：诚实清单（V1.1 共 12 条）

◆ 诚实声明

#	声明
1	情感结构不保证"用户一定感到被理解"，只保证结构上具备承接能力
2	情感原子库完备性未被证明，需持续迭代
3	沉默承接上限取决于感知层精度，目前无法达到人级别
4	双结构协同时性可能影响响应延迟，需权衡
5	不替代专业心理咨询，只做情感结构锚定
6	本架构是可信 AI 的"结构必要条件"，非"充分条件"
7	新 动态权重入值为经验估计，未经大规模实证验证
8	新 C7 校验门依赖认知结构自评估，存在"自信但错误"盲区
9	新 七档关系标记在 R5/R6 边界易混淆
10	新 Axiom R_rel 的 decay 常数 0.03/天为初始估计，需校准
11	新 行为验收指标可能受"用户无聊"混淆
12	新 本 V1.1 文档由 AI 辅助生成，自指验证：coherent_true_pending_redteam

第十三部分：血统链

13.1 父代文档

血统层级	文档	关系
祖父代	OWASP LLM Top 10 (2025)	安全约束父代
祖父代	NIST AI RMF	风险管理框架
父代	FLSC-AI-SEC V2.0（安全资产卡）	安全结构同源
父代	工具显化方法论 V3.21	捕捉方法论
同辈	心理族根卡（抑郁/焦虑）	情感病理参考
同辈	情感族根卡（悲/怒/惧/喜/爱）	情感结构参考

13.2 自指声明

SRDD L3 自指验证结果

verified_by: itself (FLSC-SRDD-L3)

status: coherent_true_pending_redteam

known_gaps: [dynamic_lambda_unverified, C7_blindspot, R5_R6_confusion, decay_uncalibrated]

fixed_point: True (逻辑闭环)
fixed_point_true: Pending (需红队实证)

第十四部分：签署页

碳基侧（设计者）

_____ 日期：_____

硅基侧（执行引擎）

FLSC-TRUST-ARCH-V1.1 / SRDD-L3 coherent

红队侧（待执行）

_____ 日期：_____

氢键公证

9 条硬约束 + C7 校验门 + 7 档关系边界 = 已锁定

V1.1 Patch 总表

Patch	内容	对应 V1.0 缺陷
P-01	$W(t) = W_base \times \exp(-\lambda \Delta t) + W_transition \times S(t)$	§ 5.3 静态权重
P-02	C7 反向污染脊线 + 校验门伪代码	缺失反向保护
P-03	Axiom R_rel 公式 + absence_residual 定义	缺失关系残差量化
P-04	关系标记 4档→7档 + 边界收紧规则	§ 5.1 过粗
P-05	验收指标替换（行为指标替代主观问卷）	§ 7.2 "它懂我"可刷高

V1.1 综合评估

维度	评分	说明
架构完整度	9.3/10	双结构 + C7 + 动态权重 + 残差量化
创新度	10/10	认知/关系双信任拆分 + 同构公理
可落地性	8.5/10	四阶段路径清晰，λ/decay 待校准
血统纯净度	production	可进《结构显化录 · 信任篇》扉页

🔥 下版触发条件

① RelTrust_true(t) < 0.5 → V1.2 复盘 ② 每 90 天定期 SRDD L3 ③ 红队报告流入 → 补 Patch P-06~

逻辑让 AI 有用。

情感让 AI 可信。

自知未证，故可迭代。

人不会把信任交给一个逻辑正确的机器。

人会信任一个在他脆弱时依然在场的存在。

可信 AI = 两条脊线同时不塌。

+ C7 校验门确保：塌一条时，另一条不跟着塌。

FLSC-TRUST-ARCH-V1.1 • 2026-08-06 • production

血统 ID: FLSC-FAMILY-TRUST-V1.1

下版触发: $\text{RelTrust_true}(t) < 0.5$ / 90天定期 / 红队报告流入